Thema:

Santander Customer Transaction Prediction

Name:

Obada Chikha

Gruppennummer:

133

Übrige Gruppenmitglieder:

Anna Fließbach

Dominik Schmid

Yujie Chen

Sprecherin:

Anna Fließbach

Zusammenfassung des Logbuchs:

1. Einleitung, Problemstellung und Zielsetzung

Die vorliegende Arbeit befasst sich mit der Vorhersage von Kundentransaktionen auf Basis des hochdimensionalen und anonymisierten **Santander Customer Transaction Prediction**-Datensatzes. Die zentrale Fragestellung lautete: *Mit welcher methode lässt sich unter Berücksichtigung extremer Klassenungleichgewichte und orthogonaler Merkmalstrukturen die maximale Trennschärfe erzielen?*

Ziel war es, einen nachvollziehbaren, hypothesengeleiteten Machine-Learning-Workflow zu entwickeln: ausgehend von einer ressourceneffizienten explorativen Datenanalyse (EDA) über lineare und probabilistische Baselines bis hin zu regulierten Gradient-Boosting-Architekturen und einem finalen heterogenen Ensemble-Modell.

2. Explorative Datenanalyse (EDA) und Datenaufbereitung

Die initiale Phase konzentrierte sich auf die Analyse der Datenstruktur, die Speichereffizienz sowie die Identifikation statistischer Eigenheiten zur Ableitung der Validierungs- und Modellierungsstrategie.

- **Speicheroptimierung:** Der Datensatz umfasst 200.000 Beobachtungen mit 200 kontinuierlichen Merkmalen (var_0 bis var_199) und belegte initial über 300MB Arbeitsspeicher. Durch die verlustfreie Konvertierung von float64 nach float32 sowie der Zielvariable target von int64 nach int8 konnte der Speicherbedarf um über 50% auf 152.8MB gesenkt und die Trainingsgeschwindigkeit signifikant gesteigert werden.
- **Klassenverteilung & Metrik-Wahl:** Die Analyse des Zielwerts ergab ein stark unausgewogenes Verhältnis von 89.95% (Klasse 0) zu 10.05% (Klasse 1). Als zwingende Konsequenz wurde die Standard-Genauigkeit (*Accuracy*) als irreführend verworfen und **ROC-AUC** als primäre Evaluierungsmetrik definiert. Zur Vermeidung von Selektionsverzerrungen (*Sampling Bias*) wurde ein striktes

Stratified 5-Fold Cross-Validation-Schema über alle Experimente etabliert.

- **Verteilungs- und Ausreißeranalyse:** Sämtliche 200 Features weisen glockenförmige, symmetrische Normalverteilungen auf. Die in den Boxplots sichtbaren Extremwerte sind natürliche Ausläufer der Gauß'schen Randbereiche (*Tails*). Auf ein künstliches Beschneiden (*Outlier Clipping*) oder Schiefe-Transformationen wurde bewusst verzichtet, um keine realen Signalinformationen zu zerstören.
- **Multikollinearitätsprüfung:** Die paarweise Korrelationsmatrix zeigte eine maximale Korrelation von lediglich 0.0809 zwischen zwei Merkmalen. Da praktisch keine lineare Multikollinearität vorliegt und die Einzelkorrelationen zum Target sehr gering ausfallen, wurde auf eine manuelle Merkmalsselektion verzichtet. Die Vorhersagekraft liegt in der additiven und nicht-linearen Aggregation schwacher Einzelsignale.

3.1 Lineare und probabilistische Baselines

Als linearer Referenzpunkt diente eine LogisticRegression. Unter 5-Fold-Cross-Validation erzielte dieses Modell einen mittleren ROC-AUC von **0.8595**.

Aufgrund der nachgewiesenen Unabhängigkeit der Features wurde als probabilistischer Ansatz **Gaussian Naive Bayes (GaussianNB)** evaluiert. Bereits auf den Rohdaten übertraf das Modell mit **0.8805** die lineare Baseline deutlich. Durch Vorschalten eines QuantileTransformer wurden die Merkmale exakt auf Standardnormalverteilungen abgebildet, wodurch die mathematische Modellannahme perfekt erfüllt wurde. Dies steigerte den ROC-AUC auf **0.8879**.

3.2 Nicht-lineare Gradient-Boosting-Verfahren

Zur Erfassung nicht-linearer Interaktionsmuster wurden zwei führende Boosting-Architekturen implementiert:

1. **XGBoost (Level-wise Tree Growth):** Die unregulierte Baseline litt ab einer Tiefe von max_depth >= 4 unter starker Überanpassung. Das Hyperparameter-Tuning bestätigte die Notwendigkeit flacher Bäume:

Mit max_depth=4, subsample=0.8, min_child_weight=10 und 400 Schätzern stieg der ROC-AUC auf **0.8836**.

2. **LightGBM (Leaf-wise Tree Growth):** Durch die blattweise Optimierung zeigte LightGBM eine überlegene Konvergenzgeschwindigkeit und Signalextraktion. Mit der Konfiguration num_leaves=63, min_child_samples=50, subsample=0.8 und learning_rate=0.08 erzielte LightGBM mit **0.8881** das stärkste Ergebnis aller Einzelmodelle.

Modell / Pipeline	Validierungs-Strategie	Train ROC-AUC	Test ROC-AUC	ROC-AUC Gap	Overfitting-Status
Logistic Regression (Baseline)	Stratified 5-Fold	0.86148	0.85949	0.00199	Minimal / Robust
GaussianNB (Raw Features)	Stratified 5-Fold	0.88233	0.88052	0.00181	Minimal / Robust
QuantileTransformer + GaussianNB	Stratified 5-Fold	0.88998	0.88793	0.00205	Minimal / Robust
XGBoost (Tuned)	Stratified 5-Fold	0.93938	0.88304	0.05634	Moderat / Akzeptabel
LightGBM (Tuned)	Stratified 5-Fold	0.99688	0.88747	0.10941	Erhöht (Leaf-wise)
Final Ensemble (Soft Voting)	Stratified 5-Fold	0.97882	0.89456	0.08426	Kontrolliert / Ausbalanciert

4. Heterogenes Ensembling (Finaler Arbeitsstand)

Im finalen Schritt wurden die drei methodisch komplementären Modellpipelines in einem **VotingClassifier** mit weicher Wahrscheinlichkeitsgewichtung zusammengeführt:

- QuantileTransformer + GaussianNB (Probabilistische Dichteschätzung, Gewicht: 0.35)
- XGBoost (Horizontale Baumstruktur, Gewicht: 0.25)
- LightGBM (Vertikale Blattstruktur, Gewicht: 0.40)

Die theoriegeleitete Gewichtung balancierte die Korrelation zwischen den beiden baumbasierten Modellen aus und nutzte die Rauschunterdrückung des Naive-Bayes-Ansatzes.

Ergebnis: Das finale Ensemble erzielte einen mittleren Test-ROC-AUC von **0.89456 (89.46)**. Dies entspricht einem signifikanten Performanzgewinn

von 0.65 Prozentpunkten gegenüber dem besten Einzelmodell und +3.51 Prozentpunkten gegenüber der linearen Baseline. Gleichzeitig reduzierte das Ensemble den Overfitting-Gap von LightGBM von 0.109 auf 0.084.



5. Aufgetretene Grenzen, Herausforderungen und Reflexion

1. **Grenzen traditioneller Merkmalsinteraktionen:** Da die synthetisch erzeugten Merkmale orthogonal sind, blieben Standard-Feature-Engineering-Ansätze (wie Polynom-Features) wirkungslos oder führten zu Dimensionsexplosionen.
2. **Kompensation von Modell-Instabilitäten:** Während tiefe Boosting-Bäume (LightGBM) dazu neigten, Stichprobenrauschen der Trainingsdaten zu memorieren, erwies sich der probabilistische GaussianNB-Zweig als extrem stabil. Erst das Ensembling glättete diese extremen Wahrscheinlichkeitsspitzen zuverlässig.
3. **Schwellenwert-Dilemma:** Da der ROC-AUC unabhängig von festen Schwellenwerten operiert, liefert die Standard-Klassifikationsschwelle 0.50 bei 90:10-Klassenungleichgewicht einen geringen Recall. Für geschäftliche Entscheidungsprozesse ist eine nachgelagerte Schwellenwert-Optimierung (z. B. Maximierung des F1-Scores oder Kostenmatrizen) erforderlich.

6. Gesamtfazit und Ausblick

Das Projekt demonstriert erfolgreich, dass durch methodisch saubere Datenvorverarbeitung, theoriegeleitete Verteilungstransformationen und das Zusammenführen heterogener Algorithmenfamilien die intrinsischen Leistungsgrenzen isolierter Modelle durchbrochen werden können.

Quellen und Hilfsmittel:

[1] **Kaggle Santander Datensatz** , Kaggle, 2026. Verfügbar unter: https://www.kaggle.com/.

[2] **scikit-learn: Machine Learning in Python (Offizielle Dokumentation)**, Scikit-Learn Developers, 2026. Verfügbar unter: https://scikit-learn.org/stable/ .

[3] **Python Machine Learning Tutorial**, W3Schools, 2026. Verfügbar unter: https://www.w3schools.com/python/python_ml_getting_started.asp .

[4] **Gemini AI (Technischer Assistent zur Fehleranalyse und Code-Optimierung)**, Google, 2026. Verfügbar unter: https://gemini.google.com/ .

Anhang

Eintrag 1: Datenladen & Speicheroptimierung (Memory Optimization)

- **Datum:** [29.07.2026]
- **Titel:** Erster Datenimport und Reduzierung der Datentyp-Größen
- **Durchgeführte Schritte & Methodik:**
  - Importieren des Santander-Datensatzes und Analyse des Speicherverbrauchs.
  - Konvertierung der Datentypen: Umwandlung von standardmäßigen float64-Werten in float32 (bzw. int64 zu int8 für das Target).
- **Ergebnisse & Beobachtungen:**
  - Der Datensatz ist mit 200.000 Zeilen und 200 Features extrem schwerfällig und belegte initial über 300 MB Arbeitsspeicher.
- **Auswirkungen & Konsequenzen (Consequences):**
  - **Speicherersparnis:** Der Speicherbedarf wurde um mehr als 50 % reduziert.
  - **Effizienz:** Das spätere Training von Modellen und das Plotten von Grafiken läuft nun deutlich schneller ab, ohne dass ein Informationsverlust bei den Fließkommazahlen entsteht.

Eintrag 2: Analyse der Zielvariablen (Target Distribution)

- **Datum:** [30.07.2026]
- **Titel:** Untersuchung der Klassenverteilung des Targets
- **Kontext / Gruppentreffen:** Eigenständige Durchführung im Rahmen der initialen EDA.
- **Durchgeführte Schritte & Methodik:**
  - Berechnung der relativen Häufigkeiten der Zielvariable.
- **Ergebnisse & Beobachtungen:**
  - Extrem ungleiche Klassenverteilung (Class Imbalance): Ca. 90 % der Daten gehören zur Klasse 0 (Kunde tätigt keine Transaktion) und nur ca. 10 % zur Klasse 1.
- **Auswirkungen & Konsequenzen (Consequences):**
  - **Metrik-Wahl:** Die Standard-Genauigkeit (Accuracy) ist vollkommen unbrauchbar (ein triviales Modell, das immer 0 vorhersagt, würde 90 % Accuracy erreichen). Es muss zwingend **ROC-AUC** als Evaluierungsmetrik genutzt werden.

    - **Validierungsstrategie:** Beim Aufteilen der Daten reicht ein einfacher Zufalls-Split nicht aus. Es muss ein **Stratified K-Fold Cross-Validation** (bzw. Stratified Train-Test Split) angewendet werden, um das 90/10-Verhältnis in allen Splits exakt zu wahren.

Eintrag 3: Analyse der Feature-Verteilungen (Distributions & Normality)

- **Datum:** [30.07.2026]
- **Titel:** Untersuchung der Verteilungsformen aller 200 Features
- **Durchgeführte Schritte & Methodik:**
    - Visualisierung von Kernel Density Estimations (KDE) für varianzstarke sowie zufällig gewählte Features.
- **Ergebnisse & Beobachtungen:**
    - Alle Features weisen perfekt unimodale, symmetrische Gauß-Verteilungen (Glockenkurven) auf.
- **Auswirkungen & Konsequenzen (Consequences):**
    - **Keine Transformationen nötig:** Aufwändige Skalierungen oder Transformationen (wie Logarithmic- oder Box-Cox-Transformationen) zur Beseitigung von Schiefe sind **vollkommen überflüssig**.
    - **Synthetische Daten:** Die perfekte Symmetrie zeigt, dass die Daten synthetisch erzeugt wurden. Eine Normalisierung (MinMax/StandardScaler) ist vor allem für spätere baumbasierte Modelle nicht erforderlich.

Eintrag 4: Ausreißer-Analyse (Boxplots & IQR-Bewertung)

- **Datum:** [30.07.2026]
- **Titel:** Visualisierung mittels Boxplots und statistische Ausreißer-Prüfung
- **Kontext / Gruppentreffen:** Finale Vorbereitung vor der Modellauswahl.
- **Durchgeführte Schritte & Methodik:**
    - Erstellung von Boxplots für ausgewählte Features

- **Ergebnisse & Beobachtungen:**
    - Es wurden leichte statistische Ausreißer (Punkte außerhalb der Whiskers) festgestellt.
    - Es gibt **keine** extremen Messfehler oder Datenkorruptionen (keine Spikes oder unnatürliche Werte).
- **Auswirkungen & Konsequenzen (Consequences):**
    - **Kein Clipping/Entfernen:** Die Ausreißer sind natürliche Bestandteile der Gauß'schen Enden (Tails) bei großen Datenmengen und dürfen nicht gelöscht werden.
    - **Modellauswahl:** Entschluss für **baumbasierte Algorithmen (LightGBM / XGBoost)** als Baseline-Modelle. Diese teilen Daten anhand von Quantilen (Quantile Splitting) und sind daher vollkommen immun gegenüber solchen leichten Extremwerten.

Eintrag 5: Umfassende Korrelationsanalyse (Multikollinearität & Feature-Target-Beziehung)

- **Datum:** [31.07.2026]
- **Titel:** Untersuchung der Feature-Redundanz und der linearen Signalstärke.
- **Durchgeführte Schritte & Methodik:**
    - Berechnung der absoluten Korrelationsmatrix über alle 200 Features mittels.
    - Extrahieren der Top 10 Features mit der stärksten Korrelation zum target und Erstellung einer vergleichenden Korrelations-Heatmap.
- **Ergebnisse & Beobachtungen:**
    - **Feature-zu-Feature:** Die maximale Korrelation zwischen zwei beliebigen Features im gesamten Datensatz liegt bei lediglich **~0.0809**. Es existiert praktisch **keine Multikollinearität**.
    - **Feature-zu-Target:** Die lineare Korrelation zur Zielvariable ist selbst bei den einflussreichsten Features sehr schwach.

- **Auswirkungen & Konsequenzen (Consequences):**
    - **Keine Feature-Eliminierung:** Da keine Redundanzen vorliegen, muss kein Feature aufgrund hoher Korrelation verworfen werden. Alle 200 Features liefern unabhängige Signale (Bestätigung synthetisch erzeugter, orthogonaler Daten).
    - **Bestätigung der Modellstrategie:** Die Vorhersagekraft liegt in komplexen, nicht-linearen Kombinationen schwacher Signale. Dies begründet final den Einsatz von Gradient-Boosting-Ensembles (**LightGBM / XGBoost**), da diese solche Muster optimal lernen können.

Eintrag 6: Lineare Baseline-Modellierung, Skalierung & Stratifizierte 5-Fold Validierung

- **Datum:** [08.08.2026]
- **Titel:** Implementierung, Optimierung und methodische Absicherung der Logistischen Regression als lineare Benchmark
- **Kontext / Gruppentreffen:** Übergang von der EDA zur Modellierungsphase (Modeling Phase) zur Etablierung einer verifizierten unteren Leistungsgrenze.
- **Durchgeführte Schritte & Methodik:**
    - **Initialer Baseline-Split:** Trennung von Features und Zielvariable sowie Durchführung eines ersten stratifizierten Splits (80/20, random_state=42) für Rohdaten-Training (LogisticRegression).
    - **Feature Scaling & Pipeline:** Aufbau einer Scikit-Learn Pipeline bestehend aus StandardScaler und LogisticRegression(max_iter=1000), um den Einfluss von Regularisierungsstrafen auf unskalierte Features zu minimieren.
    - **Stratified 5-Fold Cross-Validation:** Absicherung der Ergebnisse über den gesamten Datensatz mittels StratifiedKFold(n_splits=5, shuffle=True, random_state=42), um

das 90/10-Klassenverhältnis in jedem Split exakt zu wahren und Sampling-Bias zu eliminieren.
    - **Metrik:** Messung der Vorhersage-Wahrscheinlichkeiten (predict_proba) über **ROC-AUC**.
- **Ergebnisse & Beobachtungen:**
    - Das unskalierte Modell erzielte auf dem einfachen Split einen ROC-AUC von **0.8579**.
    - Die 5-Fold Cross-Validation mit StandardScaler steigerte das Ergebnis leicht und zeigte hohe Stabilität:
        - **Mittlerer ROC-AUC (Mean CV): 0.8595 (~85.95%**).
- **Auswirkungen & Konsequenzen (Consequences):**
    - **Statistische Absicherung:** Die geringe Varianz belegt, dass der Score von knapp 86% nicht auf Zufall beruht, sondern die reale Obergrenze rein linearer Zusammenhänge darstellt.
    - **Abschluss der linearen Phase:** Die lineare Benchmark ist damit methodisch sauber ausgereizt.

Eintrag 7: Probabilistische Modellierung & Verteilungsoptimierung (Gaussian Naive Bayes)

- **Datum:** [15.08.2026]
- **Titel:** Evaluierung und Optimierung des Gaussian Naive Bayes Classifiers mittels Quantiltransformation
- **Kontext / Meilenstein:** Systematischer Modellvergleich (Probabilistischer Ansatz vs. Lineare Baseline) auf Basis der in der EDA nachgewiesenen Feature-Unabhängigkeit.

Durchgeführte Schritte & Methodik:

- **1. Initiales Naive-Bayes-Modell (Probabilistische Baseline):**
    - Implementierung von GaussianNB()
    - Validierung über dieselbe **Stratified 5-Fold Cross-Validation** (n_splits=5, shuffle=True, random_state=42) zur direkten methodischen Vergleichbarkeit mit der Logistischen Regression.

- **2. Verteilungs- & Modelloptimierung (Quantile Transformation Pipeline):**
    - Aufbau einer Pipeline mit QuantileTransformer(output_distribution='normal', random_state=42) und GaussianNB().
    - Nicht-lineare Abbildung aller 200 Feature-Verteilungen auf eine exakte Standardnormalverteilung, um die mathematische Normalverteilungsannahme des Modells strikt zu erfüllen.
    - Evaluation über die 5 Folds zur Vermeidung von Data Leakage.
- **Metrik:** Messung der Vorhersage-Wahrscheinlichkeiten über **ROC-AUC**.

  Ergebnisse & Beobachtungen:

Modell / Pipeline-Konfiguration	**Mean ROC-AUC (5-Fold CV)**
Gaussian Naive Bayes (Raw Features)	0.8805
QuantileTransformer + GaussianNB	0.8879

Abschluss des probabilistischen Ansatzes: Der Naive-Bayes-Zweig ist damit methodisch ausgereizt und stellt einen starken Kandidaten für spätere Ensembling- / Stacking-Verfahren dar.

Eintrag 8: Gradient Boosting (XGBoost), Hyperparameter-Tuning & Feature-Importance-Analyse

- **Datum:** [19.08.2026]
- **Titel:** Implementierung, systematische Optimierung und Interpretation des XGBoost-Klassifikators
- **Kontext / Gruppentreffen:** Evaluierung nicht-linearer, baumbasierter Ensemble-Verfahren (Level-wise Tree Growth) und Schließen der Performanzlücke zur probabilistischen Baseline.
- **Durchgeführte Schritte & Methodik:**
    - **Initialer Baseline-Fit (XGBoost):** Training eines Basis-Klassifikators (n_estimators=100, max_depth=4, learning_rate=0.1) mit tree_method='hist' zur Histogramm-basierten Beschleunigung auf 200.000 Instanzen unter **Stratified 5-Fold Cross-Validation**.
    - **Validation-Curve-Analyse:** Untersuchung des Overfitting-Verhaltens durch systematische Variation der Baumtiefe (max_depth von 2 bis 5) und Gegenüberstellung von Train- vs. Validation-ROC-AUC.
    - **RandomizedSearchCV:**Durchführung eines randomisierten Suchlaufs (10 Iterationen, 5 Folds, insgesamt 50 Fits) zur gleichzeitigen Optimierung von max_depth, subsample, colsample_bytree, min_child_weight und n_estimators.
    - **Feature-Importance-Extraktion:** Ermittlung und Visualisierung der relativen Informationsgewinne (Gain / Weight) der Top-15-Merkmale des besten Modells.
- **Ergebnisse & Beobachtungen:**
    - Die unregulierte XGBoost-Baseline erzielte lediglich einen ROC-AUC von **0.8466**.
    - Die Validierungskurve zeigte ab max_depth >= 4 eine massive Schere (Train-Score > 0.98 vs. stagnierender Val-Score bei ≈ 0.887), was die Notwendigkeit flacher Bäume belegt.
    - Das Tuning über RandomizedSearchCV steigerte die Vorhersagekraft signifikant:

        - **Mittlerer ROC-AUC (Mean CV): 0.8836 (~88.36%)** mit den optimalen Parametern: max_depth=4, subsample=0.8, min_child_weight=10, n_estimators=400.
    - **Feature-Wichtigkeit:** var_81, var_139 und var_12 weisen die stärkste Trennkraft auf; der Informationsgewinn fällt flach ab.
- **Auswirkungen & Konsequenzen (Consequences):**
    - **Bestätigung des Datenraums:** Da alle 200 Merkmale gleichmäßig und additiv zur Vorhersage beitragen, führt ein manuelles Entfernen von Merkmalen (Feature Selection) zu Informationsverlust und wird verworfen.
    - **Modellsicherung:** XGBoost ist fertig optimiert und dient als zentrale Stütze für das finale Modell-Ensemble.

Eintrag 9: Gradient Boosting (LightGBM), Hyperparameter-Tuning & Feature-Importance-Analyse

- **Datum:** [22.08.2026]
- **Titel:** Implementierung, systematische Optimierung und Interpretation des LightGBM-Klassifikators
- **Kontext / Gruppentreffen:** Evaluierung blattweiser Baumstrukturen (Leaf-wise Tree Growth), Performanzvergleich zu XGBoost sowie probabilistischen Ansätzen und Schließen der Modellierungsphase für baumbasierte Einzelmodelle.
- **Durchgeführte Schritte & Methodik:**
    - **Initialer Baseline-Fit (LightGBM):** Training eines Basis-Klassifikators (`LGBMClassifier` mit `n_estimators=100`, `learning_rate=0.1`, `objective='binary'`) unter Verwendung von **Stratified 5-Fold Cross-Validation** zur standardisierten Messung von Rechenzeit und ROC-AUC.
    - **Feature-Importance-Extraktion:** Ermittlung und Visualisierung der Top-15-Merkmale basierend auf der Split-Häufigkeit (`Split Count`) des besten Modells.

- **Ergebnisse & Beobachtungen:**
    - **Baseline-Überlegenheit:** Die unregulierte LightGBM-Baseline erzielte bereits einen ROC-AUC von **0.8652** bei hoher Recheneffizienz (1m 43s für 5 Folds) und übertraf die XGBoost-Baseline (0.8466) deutlich.
    - **Optimierte Performanz:** Das Tuning via `RandomizedSearchCV` steigerte die Vorhersagekraft signifikant auf das bisher beste Einzelmodell-Ergebnis:
        - **Mittlerer ROC-AUC (Mean CV): 0.8881 (~88.81%)**
        - **Beste Parameter-Konfiguration:** `num_leaves=63`, `min_child_samples=50`, `subsample=0.8`, `n_estimators=400`.
- **Auswirkungen & Konsequenzen (Consequences):**
    - **Effizienz und Skalierbarkeit:** Der Leaf-wise-Ansatz erweist sich bei unkorrelierten Merkmalen als überlegene Boosting-Strategie und schlägt sowohl XGBoost (0.8836) als auch den Quantile-Naive-Bayes-Ansatz (0.8879).
    - **Abschluss der Einzelmodell-Phase:** Alle relevanten Modellfamilien (linear, probabilistisch, baumbasiert) sind methodisch isoliert und ausgereizt.

Eintrag 10: Multi-Model Ensembling

- **Datum:** [24.08.2026]
- **Titel:** Konstruktion, Gewichtung und Validierung eines heterogenen Ensemble-Klassifikators
- **Durchgeführte Schritte & Methodik:**
    - **Modell-Selektion:** Integration der drei stärksten optimierten Pipelines:
        - QuantileTransformer + GaussianNB
        - XGBoost
        - LightGBM

    - **Ensemble-Architektur (VotingClassifier):**
        - Verwendung von **Soft Voting** (voting='soft'), um die kontinuierlichen Wahrscheinlichkeitsverteilungen für die ROC-AUC-Berechnung präzise zu mitteln und die Modellkonfidenz zu wahren.
        - Festlegung einer theoriegeleiteten Gewichtung: [0.35, 0.25, 0.40] (höhere Gewichtung für LightGBM und Naive Bayes, Ausbalancierung der baumbasierten Korrelation).
    - **Validierung:** End-to-End-Evaluierung über **Stratified 5-Fold Cross-Validation** (StratifiedKFold, $n = 5$, shuffle=True, random_state=42).
- **Ergebnisse & Beobachtungen:**
    - Das heterogene Ensemble bricht die Leistungsgrenzen aller Einzelmodelle deutlich:
        - **Mittlerer ROC-AUC (Mean CV): 0.8946 (~89.46%)**
    - **Performanzgewinn:** Steigerung um $+ 0.0065$ (+0.65 Prozentpunkte) gegenüber dem besten Einzelmodell (LightGBM: 0.8881) und $+ 0.0351$ (+3.51 Prozentpunkte) gegenüber der linearen Baseline (0.8595).

    - **Projektstatus:** Das finale Vorhersagemodell ist methodisch sauber validiert und einsatzbereit.